Разные методы генерации из диффузионных моделей

Этап 1. Промежуточный отчёт

1. Что исследуем

Сравниваем DDIM, DPM-Solver++ 2M и Heun при одинаковом числе вызовов сети (NFE). Проверяем, как сэмплер и расположение уровней шума влияют на качество и время генерации. Веса модели фиксированы.

Эксперименты идут на T4 в Colab с float32 и batch size 64. Главный ресурсный лимит - квота GPU. На M4 Pro доступна генерация через MPS, FID считается на CPU.

2. Данные и модель

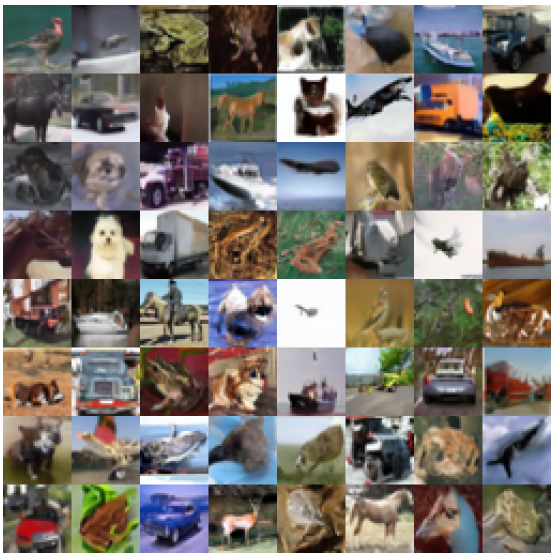
CIFAR-10 - 60 000 RGB-изображений 32×32, 10 классов. Разбиение 50 000 train и 10 000 test. Для FID используем весь train. Генерация безусловная.

Берём готовую google/ddpm-cifar10-32, ревизия 267b167, 35,7 млн параметров. Она соответствует заданию и подходит для частых прогонов на T4. В карточке весов указана Apache-2.0. На официальной странице CIFAR-10 отдельная лицензия не указана, требуется цитировать Krizhevsky (2009).

3. Baseline

DDIM из Diffusers 0.35.2, 100 шагов, eta=0, native leading, clipping=True. Начальные шумы сохранены, seeds 50000-54999.

Картинок	FID-5k / real-50k ↓	NFE	Денойзинг	На изображение
5000	15,6571	100	1505,17 с	0,3010 с



Первые 64 результата DDIM-100. Видны животные и транспорт, фоны и цвета разнообразны. Часть контуров размыта, мелкие детали искажены.

Пик CUDA allocated - 0,834 GiB. Сохранены конфигурации, шумы, тензоры, PNG и метрики. Контрольные суммы и соответствие PNG тензорам проверены.

4. Как устроены методы

Обозначим $x_t=a_tx_0+b_t\varepsilon$, где $a_t=\sqrt{A_t}$, $b_t=\sqrt{(1-A_t)}$, а A_t - накопленное произведение (1-β) из DDPM-расписания.

U-Net получает тензор [B, 3, 32, 32] и timestep t, возвращает предсказание шума ε_θ. Обвязка переводит его в оценку чистого изображения D.

Выход сети	Оценка чистого изображения D
ε	$(x_t - b_t\varepsilon_\theta)/a_t$
x_0	Выход сети без преобразования
$v = a_t\varepsilon - b_tx_0$	$a_tx_t - b_tv_\theta$

DDIM

При eta=0 шаг детерминированный. Одно предсказание сети переносит состояние с уровня t на следующий уровень s.

$$x_s = a_sD_t + b_s\varepsilon_\theta.$$

DPM-Solver++ 2M

Второй порядок получается из текущей и предыдущей оценок D. На новый узел нужен один вызов сети. При $\lambda=\ln(a/b)$, $h=\lambda_s-\lambda_t$, $r=(\lambda_t-\lambda_{prev})/h$

$$D_{corr} = D_t + (D_t-D_{prev})/(2r),$$
$$x_s = (b_s/b_t)x_t - a_s(\exp(-h)-1)D_{corr}.$$

Первый шаг выполняется без истории. На чистом конце результат равен D_t.

Heun в координатах EDM

Используем $y=x_t/a_t$, $\sigma=b_t/a_t$. Перед вызовом DDPM возвращаем $x_t=y/\sqrt{(1+\sigma^2)}$. Оценка чистого изображения $D=y-\sigma\varepsilon_\theta$ задаёт наклон $d=(y-D)/\sigma$.

Heun сначала делает Euler-шаг, затем уточняет его средним текущего и нового наклонов. Последний переход к σ=0 выполняется без второго запроса. Поэтому для N узлов NFE=2N-1. Случайные добавки отключены.

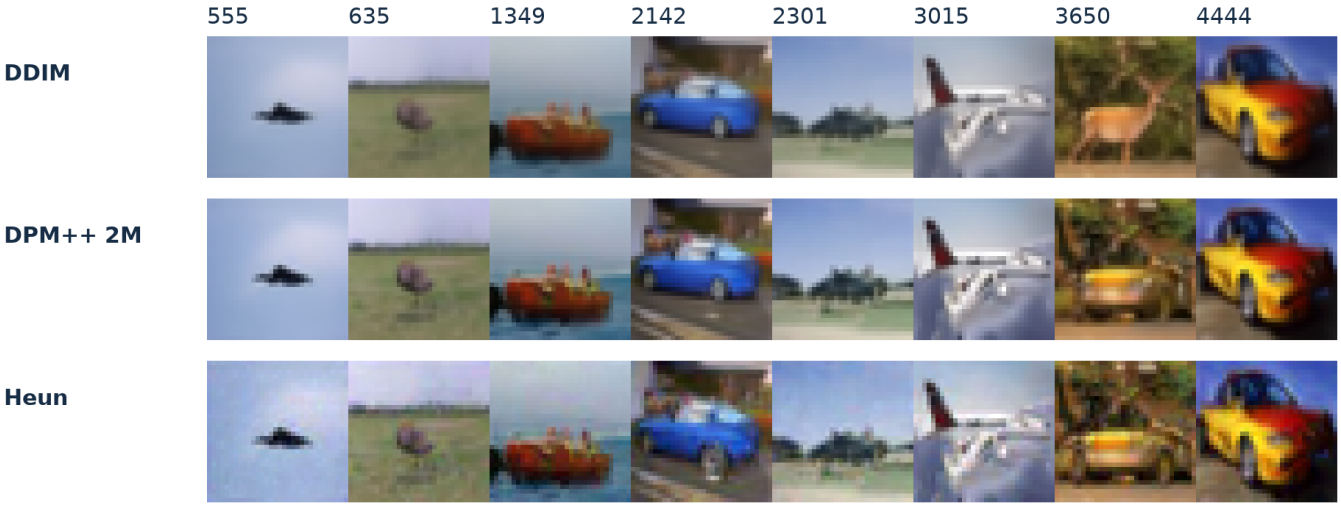
В сравнении методов фиксированы шумы, clipping=False, начало t=999 и конец σ=0. Для Heun тот же начальный шум z переводится в $y=\sqrt{(1+\sigma^2)}z$. Для DDIM и DPM++ бюджет 39 NFE даёт 39 узлов, для Heun - 20.

Все 35 тестов и 5 сверок с Diffusers прошли. Максимальная ошибка промежуточного состояния на T4 - $5{,}72\times10^{-6}$.

Первые результаты

Три собственных сэмплера запущены на одном банке из 5000 шумов. У всех uniform_t, 39 NFE, float32 и batch size 64.

Метод	FID ↓	Денойзинг, с	Секунд/изображение
DDIM	20,8112	548,78	0,1098
DPM-Solver++ 2M	18,7129	558,05	0,1116
Heun	27,0767	558,56	0,1117



В каждой колонке одинаковый начальный шум. Показаны 8 примеров из 64 просмотренных индексов, равномерно распределённых по набору.

DPM++ 2M получил наименьший FID. На примерах 1349 и 4444 у него чётче контуры. У Heun на примерах 555 и 635 заметнее зернистость. У всех методов встречаются размытые детали и искажения.

Библиотечный baseline использует другие clipping и начало траектории. Основное сравнение сэмплеров проводится внутри общей настройки.

Проверка длинного эталона в ноутбуке 04

На 16 одинаковых шумах MSE между DDIM-500 и DDIM-1000 равна $5{,}23\times10^{-6}$. Ошибки коротких методов относительно DDIM-1000 приведены ниже.

Метод при 39 NFE	MSE к DDIM-1000 ↓
DDIM	$2{,}20\times10^{-3}$
DPM-Solver++ 2M	$3{,}23\times10^{-4}$
Heun	$9{,}57\times10^{-4}$

Проверка поддерживает использование DDIM-1000 как эталона на этой малой выборке. MSE показывает близость к его результату. Качество распределения изображений оценивается отдельно через FID.

5. План экспериментов

Сравним 3 сэмплера × 3 расписания (uniform_t, log_sigma, karras с rho=7) × 3 бюджета (19, 39, 79 NFE). Из 27 конфигураций выполнены 3. Для остальных измерим FID, время и память при тех же условиях.

Затем подберём расписание для DPM++ 2M при 39 NFE. Начнём с log_sigma и трёх внутренних опор. По очереди сдвигаем каждую опору в log(σ) на ±δ, сохраняя порядок и крайние уровни. Начальное δ - 1/20 диапазона log(σ). Повторяющиеся timestep после квантования отклоняем.

Проверим до 24 кандидатов за 4 прохода. Выбираем меньшую MSE на 64 calibration-шумах. При отсутствии улучшения уменьшаем δ вдвое. Три лучших варианта проверяем на 64 validation-шумах и фиксируем один.

Гипотеза - больше шагов на средних и низких уровнях шума поможет точнее восстановить структуру и детали. Успехом считаем снижение MSE на новых шумах при равном NFE. Улучшение качества подтверждаем через FID. Время и NFE поиска учитываем отдельно.

6. Метрики и протокол

Метрика	Как считаем
FID	5000 PNG против CIFAR-10 train-50k. torch-fidelity 0.3.0, Inception 2048. Единая обработка RGB uint8.
MSE	По сырым float32-тензорам к DDIM-1000 на тех же шумах. Сохраняем ошибки изображений и стандартную ошибку среднего.
Стоимость	Счётчик forward, время денойзинга с синхронизацией и пик памяти. Прогрев перед замером. Отдельно учитываем FID и подбор расписания.

Фиксируем веса, устройство, версии, float32, batch size, clipping, края траектории и банк шумов. Основной FID-банк имеет seeds 50000-54999. Для поиска и validation отведены отдельные банки по 64 шума (seeds от 20000 и 30000).

7. Следующий этап

Завершить стандартную сетку, реализовать поиск опор и проверить выбранные настройки на 1024 новых шумах (seeds 40000-41023). Затем выполнить по два FID-прогона на банках 60000-64999 и 70000-74999. Уже полученные FID относятся к одному прогону. Найденные опоры также проверить с другим сэмплером.

Ожидаемый результат - таблицы качества и времени, графики по NFE и история поиска. Риски - квота T4, длительный FID на CPU и переобучение расписания. Используем checkpoint ZIP, отдельный validation и новые шумы после выбора настроек.